大语言模型生成运动处方的安全性、质量与应用适用性：系统评价

Safety, Quality, and Applicability of Large Language Model–Generated Exercise Prescriptions: A Systematic Review

作者：吕昕芸　指导教师：周志雄

中文版审阅稿｜2026 年 10 月 28 日。已完成综合仍为 35 项研究、37 份报告，其中 A 类 25 项、B 类 7 项、C 类 3 项；W19 为已记录的全文阶段排除。755 条题名摘要筛选台账记录 533 条排除、222 条寻求全文。对其中此前未关联的 189 条报告开展补充复核后，168 条形成摘要层面排除建议，14 篇完成全文初评，7 篇未获取；14 篇中 8 篇建议纳入、4 篇建议排除、2 篇未裁决。上述为 AI 辅助建议或未决状态，不追溯为历史人工决定。由于 8 篇新增候选尚缺完整的记录级身份、数据提取和质量评价，本稿正式综合仍保留 35 项研究。

摘要

背景：LLM 可快速生成运动计划，但输出质量、安全性和真实应用价值对应不同证据层次，需要分别评价。

目的：评价大语言模型（LLM）生成运动处方的质量、处方原则符合度、安全相关问题、输出稳定性及应用适用性。

方法：既有主检索 449 条、PubMed 补检 597 条，共 1046 条。历史重复标签复核后，755 条进入题名摘要筛选台账，其中 533 条排除、222 条寻求全文。对 189 条此前未关联报告的补充复核形成 168 条摘要排除建议、14 篇全文初评和 7 篇未获取报告；14 篇全文初评包括 8 篇建议纳入、4 篇建议排除及 2 篇未裁决。建议状态与研究者正式确认分开记录。已完成综合因此仍为 35 项研究、37 份报告（A=25、B=7、C=3），W19 排除；8 篇新增候选尚待完整数据提取和与设计相适配的质量评价。已完成综合的质量评价包括 A/B 类自建、未经验证的 9 域框架 288 条判断，以及 3 项随机 C 类研究的 RoB 2 共 15 个领域判断。未记录独立第二评价者。

结果：当前用户指定的综合集合为 35 项研究、37 份报告，包含模拟病例、多模型重复生成、真实患者或用户资料输出评价及 3 项人体实施研究。该研究集合与 755 条题名摘要库存的完整人工筛选链尚不能逐条对应。LLM 通常能够生成包含运动类型和至少一个剂量维度的结构化计划，但剂量适宜性、个体化、风险筛查、提示透明度和重复生成稳定性存在差异。W13 比较 GPT-4.1、Claude Sonnet 4.6 和 Gemini 2.5 Flash 在 6 个临床情境下的 360 份输出；Claude 同时参与生成与输出分类，存在潜在自评/测量偏倚。A/B 类安全结局主要为警告、禁忌、剂量或专家判断，不能解释为人体不良事件。3 项人体实施研究未充分报告不良事件。

结论：已完成的 35 项研究综合显示，LLM 能够生成结构化运动处方草案，但处方完整性、剂量适宜性、个体化、输出安全、可重复性和人体安全属于不同证据层次。现有证据不支持脱离专业监督的独立自动处方。189 条补充复核已缩小证据缺口，但 8 篇建议纳入研究仍需完成数据提取和质量评价，2 篇全文初评尚

未裁决，7 篇报告未获取；W34–W36 的筛选路径纠错也需形成记录。因此，本稿仍为内部一致的作者审阅稿，PRISMA 尚未最终闭合。

关键词：大语言模型；运动处方；系统评价；安全性；输出质量；可重复性

Abstract

Background: Large language models (LLMs) can generate structured exercise plans, but prescription quality, output safety, reproducibility, and human safety represent distinct evidence domains. Objective: To evaluate the quality, adherence to exercise-prescription principles, safety-related content, stability, and applicability of LLM-generated exercise prescriptions. Methods: Existing searches yielded 1,046 records; 755 entered the current screening ledger, with 533 exclusions and 222 reports sought for full text. A supplementary review of 189 previously unlinked reports produced 168 abstract-level exclusion recommendations, 14 completed full-text initial assessments, and 7 reports not obtained. The completed synthesis remains 35 studies in 37 reports (A=25, B=7, C=3); eight additional inclusion candidates await complete extraction and design-appropriate appraisal. Results: LLMs generally generated structured plans, but dose suitability, individualization, risk screening, and repeated-generation stability varied. W13 evaluated 360 outputs. Output-safety findings were not interpreted as human adverse events. Conclusions: Current evidence supports supervised drafting assistance rather than unsupervised prescribing. The PRISMA pathway remains open pending record-level integration of the supplementary review.

第一章 引言

运动处方的核心是把健康状况、运动能力与个人目标转化为可执行的动作和剂量。频率、强度、时间、类型、总量和进阶构成 FITT-VP 框架，但这些要素需要结合个体反应调整[4]。同样的训练形式，对健康青年、慢性病患者和明显肌无力者可能具有不同的负荷意义。处方评价因此既要关注要素是否出现，也要关注剂量是否适宜、监测是否可行以及何时需要停止或转诊。

LLM 能够理解自然语言需求，组织训练日程，并通过对话修改动作与剂量。现有原始研究已覆盖合成病例、抗阻和跑步训练、真实用户计划生成以及家庭和健身场景实施[5,6,10,12,16]。这种生成方式可能降低草案制作和信息解释的负担，但也把提示设计、数据完整性和专业审核变成了影响处方质量的环节。对使用者而言，语言流畅、表格齐整的计划不一定容易暴露剂量或适用条件上的缺陷。

现有评价的证据对象并不统一。专家评分测量的是输出内容；文本相似度测量的是表达或语义接近程度；用户问卷反映的是使用体验；活动量和体适能变化才涉及人体实施。即使同属“安全性”，指南符合度、专家对风险的判断与真实不良事件也不能互换。若不区分这些层次，容易把可生成、可接受或可重复误解为临床有效且安全。

本评价聚焦 LLM 实际生成或实质性修改运动处方的研究，考察输出质量、处方原则符合度、安全相关问题、稳定性和应用适用性。标准化或模拟输出、真实资料输出与人体实施证据分别综合，以明确各类结果能够支持的判断。

第二章 研究方法

2.1 研究方案与报告规范

参照 PRISMA 2020 及 PRISMA-S 报告研究选择与检索过程[1,2]。当前研究采用独立修订方案（路径 B）。原 PROSPERO 记录 CRD420261495731 不作为当前方案的前瞻性注册证明；现存修订方案形成于 2026 年 10 月 11 日，不追溯为检索或筛选前预设规则。该方案偏离在方法与局限中透明报告。

按 A/B/C 研究范围分层。分类依据资料来源、LLM 作用和是否实际实施运动，而非是否有专家参与评价。PlanFitting（W29）使用真实用户信息生成计划但未连续实施，归 B 类；包涵体肌炎研究（W31）使用标准化临床问题，归 A 类。三类不合并总体效果。

2.2 纳入排除标准与证据分层

研究需有可提取原始结果，且 LLM 实际生成或实质性修改运动处方。处方须包含具体运动类型或动作，以及至少一个可执行剂量维度：频率、强度、时间、总量或进阶。只有健康教育、人工计划解释、一般聊天或独立风险/转诊建议而无上述处方内容，不满足核心定义。

A 类指标准化、模拟或合成病例中对生成处方进行评价的研究；B 类指使用真实用户或患者资料生成并评价输出的研究；C 类要求生成计划实际进入人体实施，并有可提取的实施或人体结局。B 类用户参与系统操作不等于已执行运动；C 类无法识别 LLM 独立因果贡献时仍可描述整套干预，但不能将其效果归因于模型。

纳入公开及专用 LLM，不预设语言或研究设计限制；会议全文和预印本在具有完整方法与结果且完成重复报告核查时可纳入。全文获取状态与资格状态分开记录。研究级资格依据全文所示生成流程、动作/运动类型、至少一个可执行剂量维度及独立实证评价确定。

2.3 信息来源与检索记录

复用 PubMed/MEDLINE、Embase、Scopus、Web of Science、IEEE Xplore 及 arXiv 既有检索资料，不执行新检索。历史主检索 449 条，PubMed 补检 597 条，合计 1046 条。原论文记载主检索为 2026 年 9 月 27 日至 28 日、补检为 10 月 5 日；这些日期仅有历史记载，逐库检索式、日期、字段及限制的原始凭证尚不完整，不能视为均已独立核实。

原始导出与历史记录级数据分别保留。PubMed 主检索已恢复文本含 68 个 PMID，不代表六库 449 条均已有原始导出；IEEE 当前 18 条 RIS 对应历史 27 条的子集。既有映射可用于去重核验，但不能代替缺失数据库的完整检索凭证。

2.4 去重与研究选择

1046 条原始记录保留来源 ID 和历史去重映射。历史流程将 295 条标为重复，其中 4 条经复核恢复为不同报告，故净删除 291 条，形成 755 条筛选台账。当前台账记录 533 条题名摘要排除和 222 条寻求全文。533 条排除中，530 条来自已保存记录，MAIN-0271、MAIN-0282 和 MAIN-0290 于 2026 年 10 月 27 日由作者确认；后 3 条未追溯为历史筛选日期。历史标签、AI 建议、已保存决定与补充复核建议分栏保留。

222 条寻求全文报告中，33 条通过 DOI 与既有候选库存关联，其余 189 条进入补充复核。补充复核形成 168 条摘要层面排除建议、14 篇完成全文初评及 7 篇未获取报告；14 篇初评中 8 篇建议纳入、4 篇建议排除、2 篇未裁决。这些结果不作为重建的历史人工决定。当前工作区未包含可识别 14 篇全文、8 篇新增候选及 7 篇未获取报告的记录级文件，因此 8 篇候选尚未加入正式综合或质量评价。MAIN-0076 仅记录作

者“倾向排除”的暂定意见；W34–W36 仍存在历史题名摘要标签与当前全文候选状态之间的路径差异。W13 与 W29 的关联版本均不增加 Study 数。

2.5 数据提取与来源追溯

按 Study_ID 与 Report_ID 提取作者、年份、场景、研究设计、病例或人群、模型与版本、提示条件、LLM 作用、动作与剂量、评价方法、结局、安全性、主要结果及局限。35 项研究按 A 类 25 项、B 类 7 项、C 类 3 项分层；W13 与 W29 的多个报告按同一 Study 合并。

已读来源未报告的信息记为 NR。国家不由作者机构推断，界面或产品名称不自动当作底层模型架构。病例数、输出数、用户数、评价者数和评分记录数分别提取，不相加为总体样本量。

2.6 结局与安全性定义

主要关注处方质量、完整性、准确性、个体适配与安全相关内容；重复生成、模型差异、用户接受度、实施可行性及人体活动/体适能作为相应证据层的结局。安全性分为输出评价与人体实施事件。前者包括禁忌、风险提示、剂量、监测、停止/转诊以及专家判断；后者须有真实人体观察，不由前者推断。

若逐处方编码资料充分，“至少一次安全失效的处方比例”以至少出现一次预定义失效的可评价处方数为分子，以符合该复合指标可评价规则的处方数为分母；“各安全域失效比例”以对应域可评价处方为分母；“事件数量”记录可识别的独立失效事件。同一事件可带多个域标签，但事件数需去重；缺失域与缺失输出不按零处理，并另报缺失量。分母规则必须预先明确，不能把研究数、专家数或评分记录充当处方数。当前资料不足以跨研究计算上述总体比率。

文本相似度、唯一输出比例、动作/剂量的一致性、生成级评分 CV 和评价者一致性分别解释。人体研究未报告不良事件时写为“未报告”，不写成没有事件或已证明安全。

2.7 方法学质量与偏倚风险

质量评价按真实设计执行。32 项 A/B 类输出评价研究采用本系统评价自建 9 域框架，逐项评价问题定义、病例/数据来源、模型与生成条件、提示复现、生成次数、评价者/参照标准、结局效度、分析单位和安全结局边界。该框架不是经验证的标准化偏倚工具，不计算总分。

已完成综合中，32 项 A/B 类研究采用本评价自建、未经外部验证的 9 域框架；3 项 C 类研究按其随机分配设计采用 RoB 2。现有工作簿保存 288 条 A/B 类判断和 15 条 C 类领域判断，共 303 条，并标记为研究者已审阅确认；评价者姓名未记录，也未实施独立第二评价者或一致性统计。8 篇新增建议纳入研究尚缺完整设计信息、数据提取和适用工具评价，因此未并入 303 条结果。

2.8 证据综合

采用分层叙述性综合，报告组织借鉴不作 Meta 分析时的透明综合原则[3]。A/B/C 分别描述；在各研究内保留模型、提示、比较条件、量表方向、原始分母和时间点。不同设计或量表不合并总体效果，也不按不同研究的分值排出统一模型优劣。人体结果保留组内/组间、均值/中位数及组合干预的区别。缺失全文研究不进入已核实结果叙述，原有证据线索仍保留。

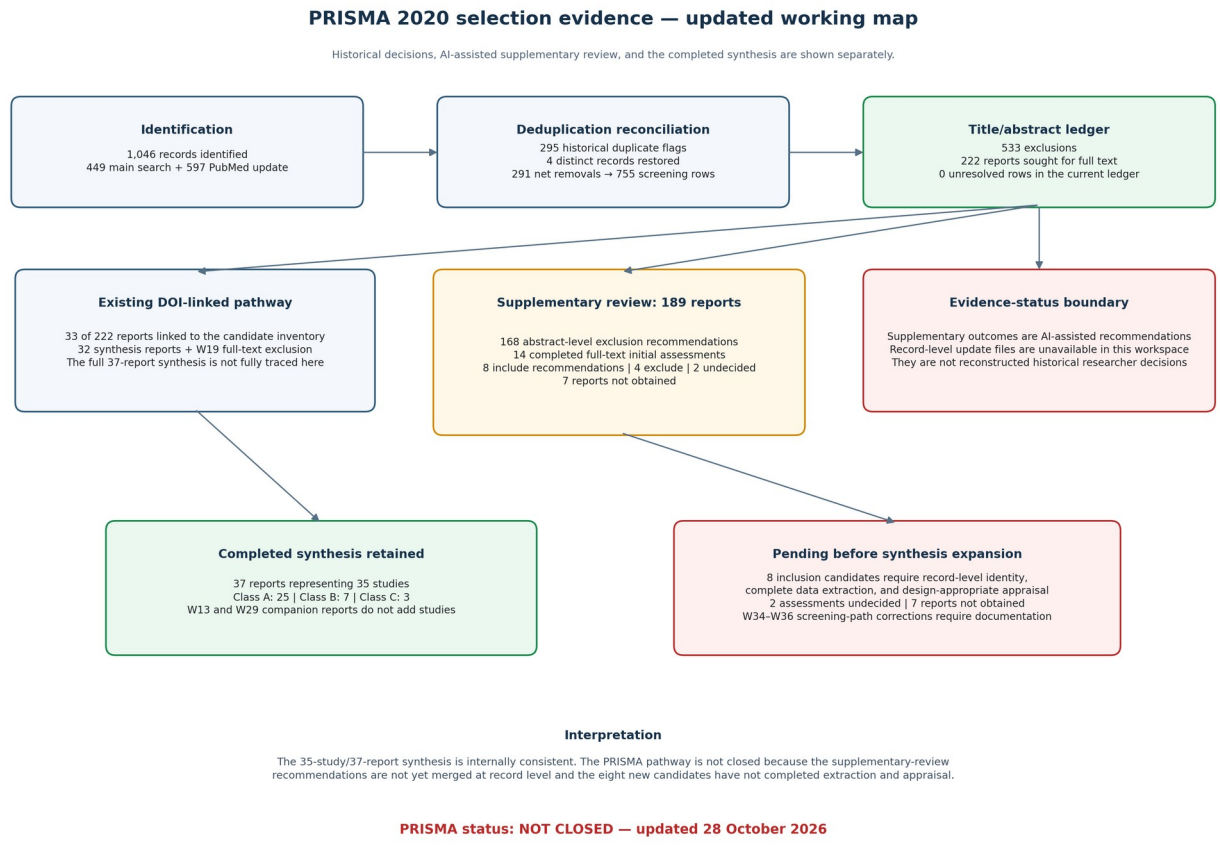
第三章 研究结果

3.1 文献检索与筛选

共识别 1046 条记录；历史重复标签 295 条，恢复 4 条不同报告后净删除 291 条，形成 755 条题名摘要筛选台账。当前台账记录 533 条排除和 222 条寻求全文。222 条中 33 条通过 DOI 关联既有候选库存；其余 189 条的补充复核形成 168 条摘要层面排除建议、14 篇全文初评和 7 篇未获取报告。14 篇全文初评包括 8 篇建议纳入、4 篇建议排除和 2 篇未裁决。由于本工作区缺少补充复核的记录级文件，以及 8 篇候选的完整数据提取和质量评价，已完成综合仍为 37 份报告、35 项研究（A=25、B=7、C=3）。W19 仍为已记录的全文排除，PRISMA 流程尚未闭合。

84 条历史冲突记录保留原筛选结果和独立 AI 建议，逐条调和依据仍不完整。MAIN-0271、MAIN-0282 和 MAIN-0290 已有 2026 年 10 月 27 日的当前决定；MAIN-0076 仅为作者暂定"倾向排除"，尚非最终资格裁决。另一条未裁决记录及 7 篇未获取报告无法从现有汇总信息中识别。W34–W36 继续纳入当前综合，但需补充有依据的纠错或重新纳入路径。

图 1　PRISMA 2020 研究选择证据图。2026 年 10 月 28 日补充复核状态与历史研究者决定分开显示；未解决节点保持开放。



751 条为历史去重工作集，755 条为恢复 4 条不同报告后的筛选库存。当前台账为 533 条排除、222 条寻求全文；222 条由 33 条既有 DOI 关联报告和 189 条补充复核队列构成。189 条更新包括 168 条摘要排除建议、14 篇全文初评及 7 篇未获取报告。建议状态不等同于历史或最终研究者决定。

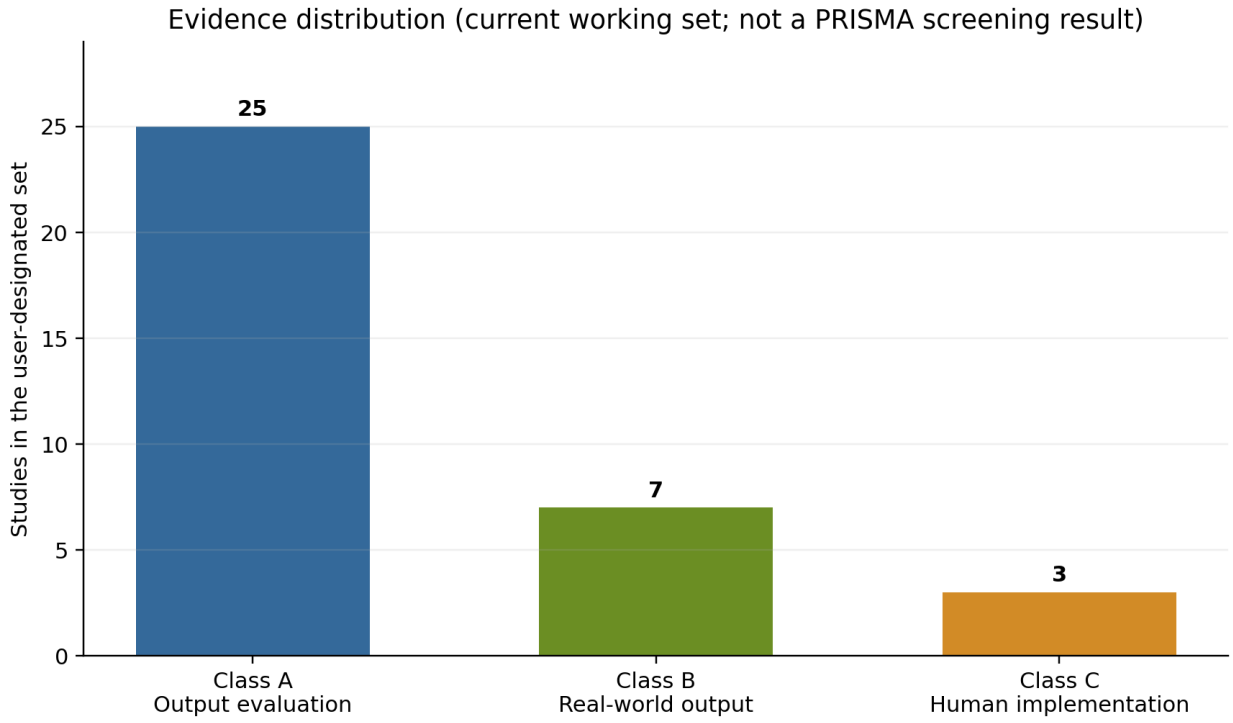
3.2 研究基本特征

最终纳入 35 项研究：A 类 25 项、B 类 7 项、C 类 3 项。A 类主要评价模拟或标准化情境下的处方完整性、质量、安全表达与重复性；B 类使用真实用户、患者资料或真实交互生成并评价输出；C 类把 LLM 生成计划用于人体实施。不同类别不直接合并总体效果。

输出研究的分析单位包括病例、生成文本、模型、评价者和评分记录，不能相加为统一样本量。B 类真实数据研究也不等于人体实施研究；例如 W03 的历史用户日志用于系统训练与离线评价，W24 和 W33 使用患者资料生成处方，但未验证患者实际执行后的效果。

全部 35 项纳入研究的作者、年份、DOI、设计、模型、运动情境、评价方法和证据位置见附表。W13 与 W29 各按一个 Study 计数，其关联预印本作为 Report 保留。W19 不进入结果综合。

图 2　已完成综合的研究类别分布（A=25，B=7，C=3）；该图不表示已闭合的 PRISMA 筛选结果。



A、B、C 分别综合，不跨层合并总体效果。

3.3 LLM 生成运动处方的完整性与质量

35 项研究普遍显示 LLM 能够输出动作、频率、强度、时间、组次或进阶中的至少部分要素，但完整性和适宜性并不一致。A 类研究覆盖抗阻、跑步、游泳、足球、心脏康复、肌骨康复、糖尿病及肾病等情境；多数采用专家自拟量表、FITT/FITT-VP 或指南符合性评价，量表和分母差异阻止跨研究总分比较。

新增全文进一步支持“可生成但需复核”的模式。W08 在 5 个模拟心脏康复病例中生成 30 日 FITT-VP 计划；W10 的 9 份糖尿病计划被专家识别出体检提醒、禁忌和强度控制缺口；W15、W16 和 W20 在高风险或康复情境中观察到结构完整与临床特异性不足并存。

W22 对 26 类人群的建议按频率、强度、时间、类型、总量和进阶编码，总体完整性有限；W25 的 8 周临床情境程序具有动作和剂量，但专家指出进阶过快；W30、W34 分别比较足球和马拉松计划，显示多个模型可形成结构化周期安排，却缺少个体健康筛查和动态调整。

真实资料输出研究提供了更贴近应用的证据。W11、W14、W23、W24 和 W33 使用真实患者资料或临床处方作为输入，能够比较个体化、负荷、指南符合性及专家方案差异；但患者资料进入生成过程不等于患者实施了计划，也不能把输出一致性解释为临床效果。

W36 的 PhysioAgent 以 MedGemma、多智能体编排和规则化安全状态机生成结构化家庭运动计划，并在 50 个临床情境和 200 个模拟 30 日周期中评价。其真实日志迁移主要验证监测模块，不等于真实患者接受自动再处方；系统性能和安全升级率仍属于离线/模拟证据。

原有 W01–W07、W21、W31 和 W35 的具体动作、剂量和专家评分继续保留于附表。各研究中“可执行”仅表示输出包含动作及至少一个剂量维度，不表示该剂量对特定患者必然适宜。

不同模型、提示层级和语言可改变处方结构与评分。研究内比较可用于识别任务特异性差异，但模型版本、情境、提示和量表均不一致，不能形成跨研究统一排行榜。

完整研究特征和逐项证据见 Table 1–2；未报告信息记为 NR。

3.4 指南符合性与安全性

安全证据主要来自输出内容。W08 报告专家安全评分，W10 识别糖尿病合并症情境中的严重缺口，W15 比较风险人群的警告和指南符合性，W16 评价安全与风险意识，W22 量化体检筛查等错误，W25 指出进阶过快，W31 记录专家对特定回答的“不安全”判断。它们均不是人体伤害事件。

W13 将禁忌、注意事项、监测和警告作为二元安全表达，三模型均出现接近天花板的安全表达分数。作者指出安全语言出现并不保证剂量完整；Claude Sonnet 4.6 同时参与生成和评价，形成潜在自评偏倚。 [23].

B 类 W24 和 W33 基于真实患者资料比较模型与临床方案，可识别处方决策差异；W29 的休息日和总量问题反映计划结构风险。真实资料并未转化为人体实施安全事件。

跨研究安全失效率仍不可计算，因为研究使用不同安全域、输出单位、专家人数和分母。三项 C 类研究均未充分报告人体不良事件，记为 NR，而非零事件。

3.5 个体化与临床适用性

B 类 7 项包括 W03、W11、W14、W23、W24、W29 和 W33。它们使用真实日志、真实用户需求、真实患者资料或真实临床处方生成并评价输出，但均不因“真实数据”自动成为人体实施研究。

W03 与 W29 继续提供系统性能和交互证据；W11 比较 ChatGPT 与智能健康促进系统生成的高血压合并症处方；W14 比较专家、AI 辅助新手和 AI 独立协议；W23 比较 GPT-4 与教练为同一真实个体制定的 16 周计划；W24 和 W33 分别使用膝骨关节炎及稳定型心绞痛患者资料进行处方比较。

这些研究支持 LLM 在真实资料输入下形成结构化方案，但结局多为专家评分、算法代理指标或输出一致性。除非计划进入人体实施并观察结局，否则不能推断依从性、有效性或伤害。

个体化评价应同时检查输入信息、动作选择、剂量、进阶、禁忌和资源约束，不能仅以输出长度或是否提及个人信息判断。

3.6 不同模型与提示方式的影响

模型比较结果具有任务依赖性。W09、W18、W21、W30、W32 和 W35 均显示版本、提示细节或语言会影响输出，但量表、生成次数与评价者不同，不能据此确定普遍最佳模型。

提示更详细通常提高结构完整性，却不能稳定解决临床筛查、强度适配和动态调整。专业审核仍是现有研究共同指出的边界。

3.7 重复生成的稳定性

W13 提供目前最系统的重复生成证据：GPT-4.1、Claude Sonnet 4.6 和 Gemini 2.5 Flash 分别针对 6 个临床情境重复 20 次，共 360 份输出。GPT-4.1 平均语义相似度 0.955、Claude 0.903、Gemini 0.950；GPT-4.1 输出均唯一，而 Gemini 仅 27.5%唯一。较高相似度可能来自稳定语义，也可能来自文本重复。[23].

W18 和 W21 进一步表明输入粒度、模型和任务会影响评分变异；W05 的少量重复生成则不足以证明等效。稳定性必须分别评价文本、动作、剂量和风险处置。

W13 的安全表达接近天花板，但部分阻力强度仍无法分类，说明“安全措辞一致”不能代替处方内容完整性。

跨研究不合并相似度、唯一输出比例、评分 CV 或专家一致性；这些指标回答不同问题。

3.8 人体实施研究结果

三项 C 类研究的运动计划均有 LLM 参与生成并进入实施，具体见 Table 3；样本量与监督条件不同，不合并总体效果。

W17 在 26 个 ASD 儿童家庭中比较 4 周活动，组间各 13[12]。原文报告使用 ChatGPT 4.0。推荐活动包括平衡步行 5 分钟、抛接球 10 分钟等，父母接受三次 40 分钟培训并在研究者支持下每周实施 3 次、每次 40 分钟。LTEQ 均值由 6.69 升至 34，对照由 7.46 变为 7.23；Table 3 交互 $F(1,24)=353.069$，$P<0.001$，$\eta p^2=0.936$。该结果来自家长报告，并与培训、亲子参与和 WhatsApp 答疑共同发生，不能解释为 LLM 单独提高活动量。

W26 为 9 名 19 岁健康超重男性提供 8 周运动，干预 6 人、对照 3 人[14]。方法概述有氧、抗阻和柔韧主训练 45–60 分钟，每周 3 次，但附录第 3–4 周 HIIT 为 20–30 分钟。处方示例与方法概述存在差异，实际逐课完成量未报告。8 周末 BMI 中位数为 22.99 与 24.46kg/m²（P=0.020），3 分钟原地抬膝后心率为 128 与 152bpm（P=0.019），30 秒坐站为 37 与 32 次（P=0.019）。这些是末次组间中位数比较，不是均值或组间变化值。对照不接受运动干预，结果不能证明 LLM 优于专业人员处方；极小样本和受伤排除条款仍限制解释。

W27 比较 GPT-4 固定方案与私人教练方案，两组各 10 名男性，训练 12 周、每周 3 次、每次 90 分钟[15]。GPT 组左臂力量由 20.31±3.80 升至 22.99±4.05kg（组内 P<0.001）。教练组多项指标有组内变化，但其方案每 4 周重测并调整，GPT 组最大力量基准 12 周未修改，两组支持方式不同。不能通过一组显著、另一组不显著判断两种服务的相对效果。

三项研究均未报告人体不良事件结局，记为 NR。未报告不代表零事件，也不证明实施安全。W26 把训练中受伤列入排除条件，但尚无法从现有报告确认该条款实际影响了多少人；不能据此填造伤害或退出人数。

3.9 研究质量与偏倚风险

已完成综合中的 32 项 A/B 类研究采用本评价自建 9 域框架，该框架未经外部验证，不计算总分或跨研究"低风险比例"。3 项 C 类研究报告随机分配，采用 RoB 2。已保存结果包括 288 条 A/B 判断和 15 条 C 类领域判断，均标记为研究者已审阅确认；评价者身份未记录，也不声称存在独立第二评价者。W13 中 Claude Sonnet 4.6 既参与生成又协助 FITT 分类和安全表达识别，构成潜在模型自评或测量偏倚。8 篇新增候选尚未进入质量评价。

三项 C 类研究的已保存 RoB 2 判断均显示目标结局至少有一个高风险领域。主要问题包括 W17 非盲法家长自报结局，W26 可能存在随机后排除和选择性报告，以及 W27 以组内显著性替代充分的组间效应。这些判断涉及人体结局报告偏倚，不能用于证明 LLM 导致了观察到的变化。

第四章 讨论

4.1 结构化处方生成的能力与边界

35 项纳入研究显示，LLM 已能在多种运动和康复场景中生成结构化方案，其现实价值主要是快速形成可供专业人员核对和修改的草案。研究数量增加并未消除处方剂量、个体适配、风险处置和动态调整方面的差距。

证据仍以输出评价为主：A 类 25 项、B 类 7 项，只有 C 类 3 项进入人体实施。数量结构说明当前领域更擅长证明"能生成"，尚不擅长证明长期有效、安全或优于专业人员。

4.2 剂量、个体化与风险处置

完整的 FITT-VP 结构并不保证剂量适配。W06 详细计划的总体评分提高，健康筛查却仅达到中性水平，且仍有进阶问题；W31 的 MRC 2/5 情境则提示，动作看似合理也可能忽略双侧无力、辅助方式可行性或疾病特异性证据。这些发现需要围绕具体动作和患者条件解释，不能由总分替代专业判断。

对风险处置的评价还需要明确参考标准。专家可能对相同频率或治疗方式提出不同意见，W31 已显示这种差异；W29 的时间限制也可能使系统难以同时满足休息规则。因此，应分别记录模型建议、参考处置、支持理由及不确定性。当前不能用专家意见分歧或缺一条安全提醒直接计算通用危险率。

提示更详细可能有帮助，但也提高了使用门槛。W06 的提示信息与追问次数同时变化，W05 也存在评分者一致性限制。不能据这些结果要求所有使用者只需"写好提示"便能获得可靠处方。模型应辅助信息结构化，专业人员仍需核对输入是否足以作出处方判断。

4.3 稳定性与处方质量的区别

W21 提供了直观例子：平均评分较低的模型反而有更小的生成级 CV。持续生成相似结果既可能反映稳定，也可能反复保留相同缺陷。W05 的未检出评分差异则受重复次数少和评分者一致性不足影响，不能视为等效性证据。

后续评价应把文本、动作、剂量和风险处置四层重复性分别报告。同一输入下的模型参数、会话历史和版本需要记录；评分稳定性应与具体内容的一致性同时检验。单次研究内表现较好不等于模型在所有人群或后续版本中更优，也不能从本评价形成统一排行榜。

4.4 输出安全与人体安全的证据差距

输出安全分可以帮助定位需要专业复核的内容，却不能直接预测伤害。W31 的 4/12 为评价者比例，W03 的 4.8/5 为计划评分，W29 休息日规则反映计划结构。这些指标的分母和测量对象不同，即使数值可用，也不宜统一换算为“安全率”。

三项人体研究均未报告不良事件，尚不能判断未发生事件还是未系统观察。正式人体研究需预先定义事件类型、严重性、暴露时间、退出原因和监督强度，并记录全部参与者。受伤后排除尤其需要透明说明，以避免只分析完成者而低估风险。现有证据既不足以断言 LLM 普遍安全，也不足以将所有输出问题等同实际伤害。

4.5 真实应用与专业人员协作

真实数据并不自动意味着真实应用效果。W03 使用真实日志，但满意度和目标匹配部分是代理指标；W29 使用真实个人需求，却在模拟后续情境中调整计划。它们为系统开发和交互设计提供依据，不能代替长期追踪。

C 类研究显示，在家长培训、研究者答疑或教练参与的条件下，LLM 生成计划可以进入运动实施。对于运动科学与康复实践，更可行的用途是草案组织、方案沟通与修改记录，而非把生成结果直接当作个体化医疗决定。对疾病、显著肌无力或负荷风险较高者，专业人员应复核禁忌、强度、进阶和停止条件，再依据实际反应调整。当前不能宣称该协作模式已优于常规专业服务。

作为背景文献，WMRE2030 提出可穿戴、多组学与实时反馈构成日尺度闭环[22]。其启示是将处方置于持续观察与调整中，而不是只评价一次文本。但该文为框架性综述，不是本评价候选的临床试验证据，也不能据此补写已开展的反馈流程或疗效。此前学习材料中的 FITT-VP 研究与游泳研究已分别按 W07、W21 记录，不重复计数。

4.6 异质性与本评价的局限

755 条题名摘要台账已有当前或恢复决定：533 条排除、222 条寻求全文。对 189 条此前未关联报告的补充复核将其分为 168 条摘要排除建议、14 篇完成全文初评和 7 篇未获取报告；14 篇中 8 篇建议纳入、4 篇建议排除、2 篇未裁决。但本工作区缺少该更新的记录级证据文件，不能把这些建议直接并入正式筛选台账、数据提取或质量评价。W34–W36 仍有未记录完整的跨阶段状态差异，因此 PRISMA 尚未闭合。

其次，部分数据库仍缺完整原始导出或执行凭证。295 条是历史重复标签，最终删除 291 条是恢复 4 条不同报告后的修正结果；751 与 755 反映修正前后的不同工作口径。

A/B 类 9 域框架为本评价自建且未经外部验证。已完成 35 项研究综合保存 303 条逐项判断，其中 288 条为 A/B 框架判断、15 条为 C 类 RoB 2 领域判断；工作簿标记为研究者已审阅确认，但评价者姓名未记录，亦无独立第二评价者或一致性统计。8 篇新增候选尚未完成适用工具评价。输出安全评价继续与人体不良事件严格区分。

最后，模型、版本、提示、情境、量表和分析单位高度异质，且人体不良事件报告不足。因此不进行 Meta 分析，不形成总体安全率或模型排行榜。

4.7 未来研究方向

后续输出研究应公开原始提示、参数、全部生成结果及失败输出，用标准化病例覆盖不同训练水平、疾病和可执行约束，并预设风险处置参考标准。相同任务应有足够重复生成，分别检查剂量、动作和安全决策，而非只报告相似度或平均分。

真实应用研究应区分模型、知识约束、专业支持及动态调整的贡献，预先指定主要结局和分析单位。人体研究需采用能够回答增量价值的比较设计，报告依从性、随访、不良事件和资源投入。工具选择应与真实设计一致，不能因传统量表易用就强行评分。

第五章 结论

已完成的 35 项研究综合显示，LLM 能够生成结构化运动处方草案，但处方完整性、剂量适宜性、个体化、安全表达和重复稳定性并不一致。A/B 类输出评价与 C 类人体实施证据不可互换；“未报告不良事件”不等于零事件。现有证据支持在专业监督下将 LLM 作为辅助工具，不支持独立自动处方。补充复核识别出 8 篇新增纳入候选，但因尚缺完整数据提取和质量评价，未并入正式综合；另有 2 篇全文初评未裁决、7 篇报告未获取，W34–W36 筛选纠错路径仍需记录。因此本稿尚不具备正式投稿条件。

附表

各表描述当前已完成综合的 35 项研究（A 类 25 项、B 类 7 项、C 类 3 项）和 37 份报告。NR 表示原文未报告；PENDING 表示证据或研究者确认尚未解决。8 篇新增建议纳入研究尚未进入表格和正式综合。PDF 证据位置采用原文物理页码。

表 1　已完成综合研究的基本特征（第一部分）

研究编号/作者-年份	类别/研究设计	人群/数据来源	LLM/生成条件
W01	Dergaa 2024 / A	模拟病例输出评价；专家批判性评价	GPT-4；5 个合成健康/疾病病例
W02	Havers 2025 / A	模拟训练计划多模型比较；专家评价	GPT-3.5、Copilot、Gemini；虚构高级力量训练者
W03	He 2026 / B	真实世界训练日志驱动的模型开发与性能评价	LLM-SPTRec 与通用 LLaMA-2；SportFit-1M 用户数据
W04	Washif 2024 / A	模拟阻力训练处方比较	GPT-3.5、GPT-4；2 名健康虚构对象
W05	Havers 2025 / A	重复生成与专家评价	GPT-4、Gemini；虚构增肌对象
W06	Düking 2024 / A	模拟跑步计划、提示信息梯度与专家评价	ChatGPT；虚构跑者
W07	Feng 2026 / A	30 个模拟病例、多模型 FITT-VP 输出评价	GPT-4o、Claude 3.7、DeepSeek R1、

研究编号/作者-年份	类别/研究设计	人群/数据来源	LLM/生成条件
			Grok-3；30 个合成病例
W08	Perrero 2026 / A	5 个模拟心脏康复病例的输出评价	DeepSeek-V3；5 个心脏康复病例
W09	Genç 2026 / A	模拟阻力训练计划的混合方法专家评价	ChatGPT-3.5、4o、4.1；虚构健康青年男性
W10	Akrimi 2025 / A	3 个虚构 T2DM 病例、9 份计划的专家评价	ChatGPT-4o；3 个 T2DM 病例
W11	Xu 2024 / B	真实患者资料驱动的两系统处方比较	ChatGPT-4.0、IHPS；10 名高血压合并症患者
W12	Wachholz 2025 / A	单份 AI 跑步计划的专家质性评价及使用者调查	ChatGPT-3.5；初级半马跑者情境；119 名调查对象
W13	Lee 2026 / A	实验性观察研究；3 个 LLM×6 个临床情境×每情境 20 次重复生成（360 份输出）	GPT-4.1、Claude Sonnet 4.6、Gemini 2.5 Flash；6 个临床/健康情境
W14	Sortino 2026 / B	5 份真实骨科处方驱动的横断面盲法专家评价	AI 单独、初学者+AI、专家；5 份真实骨科处方
W15	Choi 2026 / A	复杂高风险模拟病例的结构化专家评价	Gemini 2.5；3 个高风险合成病例
W16	Cheng 2026 / A	5 个虚拟 AWS 病例的双模型盲法专家评价	ChatGPT、DeepSeek；5 个腋网综合征虚拟病例
W17	Aydemir 2025 / C	人体实施的对照性前后测可行性研究	ChatGPT；26 个 ASD 儿童家庭
W18	Yang 2026 / A	重复生成交叉设计及盲法专家评价	GPT-4；健康训练情境

表 1（续）　处方、评价与证据来源

研究编号	运动类型/剂量	评价方法/分析单位	证据来源
W20	Cali 2026 / A	5 个模拟运动损伤病例的混合方法专家评价	ChatGPT-4.1；5 个运动损伤病例
W21	Zhao 2026 / A	模拟游泳情境、多模型重复生成专家评价	ChatGPT、Gemini、DeepSeek、豆包；1 个 100 m 自由泳模拟运动员
W22	Zaleski 2024 / A	26 类标准化人群的输出编码混合方法研究	ChatGPT；26 个临床人群/情境
W23	Li 2025 / B	单一真实个体资料驱动	GPT-4；1 名真实个体

研究编号	运动类型/剂量	评价方法/分析单位	证据来源
		的计划比较研究	
W24	Gürses 2025 / B	40 例真实膝骨关节炎患者资料驱动的输出评价	ChatGPT-4o、Gemini Advanced；40 名膝骨关节炎患者
W25	Onan 2025 / A	3 个临床病例情境的程序生成与专家评价	ChatGPT-4.0；3 个临床病例
W26	Philuek 2025 / C	人体实施的先导对照研究	ChatGPT/GPT-4；健康超重青年
W27	Genç 2025 (Digital coaches) / C	人体实施的对照研究	GPT-4（DOI 摘要已确认）；20 名男性
W28	Enichen 2025 / A	30 个虚构病例的 AI 与专家建议盲法比较	GPT-3.5；30 个虚构患者病例
W29	PlanFitting 2025 / B	真实用户交互式计划系统评价研究	LLM 对话代理；个体化运动计划用户研究
W30	Yang 2026 (soccer) / A	六模型足球训练计划比较与专家评价	6 种生成式 AI；足球训练情境
W31	Schütze 2026 / A	6 个标准化 IBM 问题的专家评价	ChatGPT；IBM 患者运动情境
W32	Fu 2026 / A	多临床情境、多模型康复程序质量与可读性评价	4 种 LLM；多肌骨临床情境
W33	Hüzmeli & Akkuş 2026 / B	40 例真实稳定型心绞痛病历驱动的输出比较	ChatGPT-5.2、Gemini Advanced；稳定型心绞痛/CCS 病例
W34	Montaruli 2026 / A	八个 AI 引擎马拉松计划的描述性原始输出比较	多种生成式 AI；初/中/高级跑者
W35	Bezruk 2026 / A	CKD 模拟病例、多模型多语言输出评价	ChatGPT、Gemini、Copilot；CKD/血液透析康复情境
W36	PhysioAgent 2026 / A	50 个临床情境与 200 个模拟随访周期的多智能体系统评价	多 Agent LLM；50 临床情境+200 模拟事件

表 2　运动处方质量、安全相关证据与主要结果

研究编号	主要发现	安全证据/分母	解释边界
W01	总体偏安全和保守；疾病特异性与目标精度不足	A/B：输出安全；C：人体不良事件 NR	pp.2–3 Methods；p.5 Table 2；pp.8–12

研究编号	主要发现	安全证据/分母	解释边界
W02	整体中等；模型间差异少，均需专业修订	A/B：输出安全；C：人体不良事件 NR	pp.2–7 Methods/Tables 4–5；pp.16–26 outputs
W03	知识图谱系统安全评分 4.8/5，通用 LLM 3.1/5	A/B：输出安全；C：人体不良事件 NR	p.3 schema；pp.6–11 Methods/Results
W04	可作草案；性别差异不足，需细化	A/B：输出安全；C：人体不良事件 NR	pp.2–5 Methods/Results
W05	27/28 项差异未达显著；详细提示质量更高	A/B：输出安全；C：人体不良事件 NR	pp.5–6；pp.16–33 appendices
W06	19、11、1 项指标评分低于 3，随输入增加而改善	A/B：输出安全；C：人体不良事件 NR	pp.2–5；pp.9–17 outputs
W07	总分依次 50.23、47.42、44.02、40.30/60	A/B：输出安全；C：人体不良事件 NR	pp.3–6 Methods/Tables 2–3
W08	指南 4.5/5，安全 5.0/5；未发现明显不安全处方	A/B：输出安全；C：人体不良事件 NR	p.1 abstract；pp.2–5 Methods/Results/Table 2
W09	4.1 评分较高；仍有风险识别和个体化不足	A/B：输出安全；C：人体不良事件 NR	pp.1,3–5 Methods/output；pp.6–13 Results
W10	多数计划存在安全缺口，复杂并发症最明显	A/B：输出安全；C：人体不良事件 NR	pp.1,3–8 Tables 2–4/Results
W11	GPT 准确性 4.64/6、完整性 2.25/3、适用性 3.05/4	A/B：输出安全；C：人体不良事件 NR	p.1 Methods；pp.5–12 prescriptions/results
W12	AI 计划信任评分 3.73 vs 3.36；不等同于安全验证	A/B：输出安全；C：人体不良事件 NR	pp.1–4 Methods/Results
W13	相似度 0.903 至 0.955；唯一输出率 27.5%至 100%	A/B：输出安全；C：人体不良事件 NR	p.2 Abstract；pp.4–6 Methods；pp.7–12 Tables 1–6；pp.19–24 Supplementary Material
W14	专家最佳，初学者+AI 居中，AI 单独最低	A/B：输出安全；C：人体不良事件 NR	p.1 abstract；pp.3–10 Methods/Results
W15	Stage 2 多有改善；Stage 3 不稳定；ICC 0.139	A/B：输出安全；C：人体不良事件 NR	p.1 abstract；正文 Methods/Results 及 rubric
W16	DeepSeek 总体较优；ChatGPT 更常出现泛化和鉴别遗漏	A/B：输出安全；C：人体不良事件 NR	pp.4–9 Methods/Tables 2–5/Results

研究编号	主要发现	安全证据/分母	解释边界
W17	干预组 LTEQ 6.69 升至 34；未报告不良事件结局	A/B：输出安全；C：人体不良事件 NR	pp.3–6 Methods/Tables 2–3
W18	详细提示安全 3.95 vs 3.33/5，输出波动较小	A/B：输出安全；C：人体不良事件 NR	p.1 abstract；正文 Methods/Results
W20	总体 3.85/5；ACL 1.88，锁骨骨折 5.00	A/B：输出安全；C：人体不良事件 NR	p.1 abstract；正文 6 周程序与专家评价
W21	ChatGPT 质量最高；豆包最稳定但质量较低	A/B：输出安全；C：人体不良事件 NR	pp.3–10 Methods/Tables 2,5
W22	完整性及准确性已报告；安全分母不能直接按 26 病例推算，全文待提取	A/B：输出安全；C：人体不良事件 NR	p.1 abstract；pp.3–6 coding/results
W23	以同一真实个体资料比较 GPT-4 与教练制定的 16 周计划；能够形成动作与剂量，但证据仍为单病例输出比较	A/B 类输出质量与适用性；非人体实施安全	p.1 Abstract；Methods/prompts/rubric 及 Results
W24	以 40 名膝骨关节炎患者资料比较 ChatGPT-4o、Gemini Advanced 与康复处方；属于真实资料输出评价	A/B 类输出安全与处方差异；非人体不良事件	p.1 Abstract；40 例患者 Methods/Results
W25	8 周情境方案包含动作和剂量；专家指出部分早期负荷及进阶安排过快	输出剂量与进阶风险；非人体不良事件	p.1 Abstract；Appendix/Table 2 及 8 周方案
W26	末次 BMI 22.99 vs 24.46 kg/m²（P=0.020）；抬膝后心率 128 vs 152 bpm（P=0.019）；坐站 37 vs 32 次（P=0.019）	人体不良事件 NR；受伤列为排除条件，实际事件数未报告	p.2 Methods；p.4 Table 2；pp.9–11 Appendix
W27	GPT 组左臂力量 20.31±3.80 至 22.99±4.05 kg（组内 P<0.001）；组内显著性不能替代组间效应	人体不良事件 NR	pp.3–6 Methods/Tables 1, 3–4
W28	研究以个体资料生成并由专业人员评价个性化运动计划；支持输出可生成性，不代表人体实	输出质量与潜在风险；非人体不良事件	pp.1–3 Methods/Table 1/Results

研究编号	主要发现	安全证据/分母	解释边界
	施效果		
W29	15/18 份初始计划满足运动总量要求，14/18 含休息日；FITT 均分 5.67/4.28/5.06/3.89	专家指出连续训练的疲劳/损伤风险；无人体实施事件	pp.6, 8–9, 13 Fig.1/Tables 2–3
W30	评分、可读性已报告；个体化健康筛查不足，全文待核查	A/B：输出安全；C：人体不良事件 NR	pp.1–5 Methods/Results
W31	Q4 有 4/12 名评价者判为错误且不安全；Q3 为 3/12 完整准确、6/12 安全但不完整、3/12 安全但基础	专家输出安全判断；不是 4 名患者或 4 份处方发生伤害	pp.2–6 Methods/Table 1/Results
W32	混合咨询任务；仅提取可执行康复子集，1476 总回答不可作处方分母	A/B：输出安全；C：人体不良事件 NR	pp.3–18 Methods/quality/readability/results
W33	使用稳定型心绞痛患者资料比较 LLM 生成的运动康复方案；属于真实资料输出评价	输出质量与风险处置；非人体不良事件	pp.1–9 Methods/Tables/Results
W34	多模型可生成结构化马拉松周期安排，但健康筛查、个体化及动态调整仍有限	输出质量与潜在负荷风险；非人体不良事件	pp.3–13 Prompt/Tables 1–3/Comparison
W35	英语输出通常更详列进阶、监测和透析中训练；研究未提供可比较的人体效果	血管通路、禁忌和症状监测均属输出安全评价	pp.3–12 Methods/Results/Figures 1–6
W36	PhysioAgent 在 50 个临床情境和 200 个模拟 30 日周期中评价处方生成与监测；真实日志迁移不等于人体再处方	规则化安全升级及模拟监测；非人体不良事件	pp.4–10 Architecture/Datasets/Results/Ablation

表 3　人体实施研究证据

研究编号/设计	干预/对照	结局/原始分析	安全性/局限性
W17	人体实施的对照性前后测可行性研究	4 周、每周 3 次、每次 40 min	干预组 LTEQ 6.69 升至 34；未报告不良事件结局；人体不良事件：NR
W26	人体实施的先导对照研	8 周；BMI 22.99 vs 24.46 kg/m²	极小样本；受伤排除时

研究编号/设计	干预/对照	结局/原始分析	安全性/局限性
	究	（P=0.020）；抬膝后心率 128 vs 152 bpm（P=0.019）；坐站 37 vs 32 次（P=0.019）	点不清；人体不良事件 NR
W27	人体实施的对照研究	12 周；两组各 10 人；GPT 组左臂力量 20.31±3.80 至 22.99±4.05 kg（组内 P<0.001）	主要报告组内比较；两组支持方式不同；人体不良事件 NR

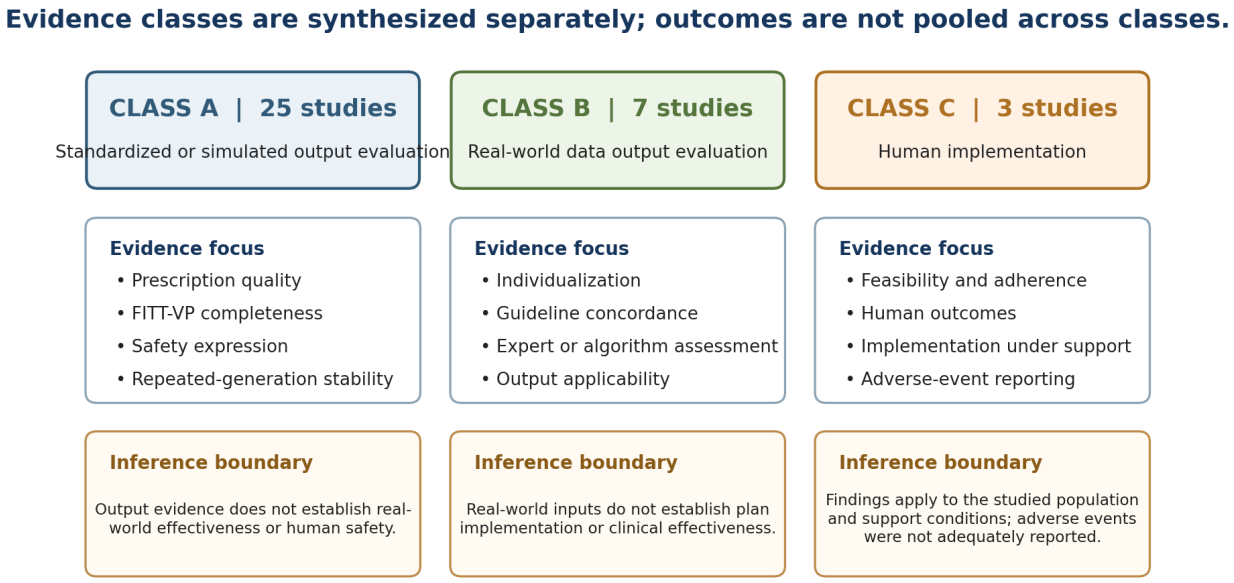
表 4　结构化质量评价证据与确认状态

研究编号/类别	评价框架与对象	证据/AI 辅助判断	研究者确认状态
W01	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W02	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W03	B / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W04	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W05	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W06	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W07	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W08	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W09	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W10	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W11	B / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not

研究编号/类别	评价框架与对象	证据/AI 辅助判断	研究者确认状态
			recorded
W12	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W13	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W14	B / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W15	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W16	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W17	C / RoB 2	AI 建议总体高风险	AI suggestion only; final researcher rating not recorded
W18	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W20	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W21	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W22	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W23	B / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W24	B / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W25	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W26	C / RoB 2	AI 建议总体高风险	AI suggestion only; final researcher rating not recorded
W27	C / RoB 2	AI 建议总体高风险	AI suggestion only; final researcher rating not

研究编号/类别	评价框架与对象	证据/AI 辅助判断	研究者确认状态
			recorded
W28	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W29	B / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W30	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W31	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W32	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W33	B / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W34	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W35	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded
W36	A / 9 域输出评价框架	逐域证据已完成；不计算未经验证的总体分级	AI suggestion only; final researcher rating not recorded

图 3　证据类别及推断边界



Conceptual evidence map. Counts reflect the author-designated working set; this is not a PRISMA selection result or risk-of-bias score.

概念性证据图；不表示效应量、偏倚风险等级或不良事件发生率。

投稿声明——需作者确认

数据可用性：PENDING。作者需确认研究级提取数据、筛选记录和质量评价工作簿是否公开，并在适用时提供仓储链接。

作者贡献：PENDING。各作者需按照目标期刊要求确认贡献角色，不能根据指导教师字段推断贡献。

资金支持：PENDING。现有项目材料未提供可核实的资助信息，需作者确认。

利益冲突：PENDING。需作者确认。

伦理声明：本研究为已发表文献的系统评价，原则上不涉及新增人体研究伦理审批，仍需作者及期刊确认。

生成式人工智能使用声明：AI 工具协助记录整理、证据提取和语言编辑。作者需在投稿前确认具体工具、使用范围及责任声明。

补充材料：研究提取和证据文件已整理于随附工作簿；最终文件命名与上传要求仍需按目标期刊当期指南确认。

参考文献

1. Page MJ, McKenzie JE, Bossuyt PM, Boutron I, Hoffmann TC, Mulrow CD, et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. BMJ. 2021;372:n71. doi:10.1136/bmj.n71.

2. Rethlefsen ML, Kirtley S, Waffenschmidt S, Ayala AP, Moher D, Page MJ, et al. PRISMA-S: an extension to the PRISMA Statement for Reporting Literature Searches in Systematic Reviews. Syst Rev. 2021;10(1):39. doi:10.1186/s13643-020-01542-z.

3. Campbell M, McKenzie JE, Sowden A, Katikireddi SV, Brennan SE, Ellis S, et al. Synthesis without meta-analysis (SWiM) in systematic reviews: reporting guideline. BMJ. 2020;368:l6890. doi:10.1136/bmj.l6890.

4. Garber CE, Blissmer B, Deschenes MR, Franklin BA, Lamonte MJ, Lee IM, et al. Quantity and Quality of Exercise for Developing and Maintaining Cardiorespiratory, Musculoskeletal, and Neuromotor Fitness in Apparently Healthy Adults. Med Sci Sports Exerc. 2011;43(7):1334-1359. doi:10.1249/MSS.0b013e318213fefb.

5. Dergaa I, Ben Saad H, El Omri A, Glenn J, Clark C, Washif J, et al. Using artificial intelligence for exercise prescription in personalised health promotion: A critical evaluation of OpenAI's GPT-4 model. Biol Sport. 2024;41(2):221-241. doi:10.5114/biolsport.2024.133661.

6. Havers T, Jelonnek C, Masur L, Isenmann E, Sperlich B, Geisler S, et al. A professional assessment of training plans for muscle hypertrophy and maximal strength developed by generative artificial intelligence. Biol Sport. 2025;42(4):353-380. doi:10.5114/biolsport.2026.152350.

7. He Z, Wang J, Zhang B, Li Y. Knowledge-grounded large language model for personalized sports training plan generation. Sci Rep. 2026;16(1):6793. doi:10.1038/s41598-026-37075-z.

8. Washif J, Pagaduan J, James C, Dergaa I, Beaven C. Artificial intelligence in sport: Exploring the potential of using ChatGPT in resistance training prescription. Biol Sport. 2024;41(2):209-220. doi:10.5114/biolsport.2024.132987.

9. Havers T, Masur L, Isenmann E, Geisler S, Zinner C, Sperlich B, et al. Reproducibility and quality of hypertrophy-related training plans generated by GPT-4 and Google Gemini as evaluated by coaching experts. Biol Sport. 2025;42(2):289-329. doi:10.5114/biolsport.2025.145911.

10. Düking P, Sperlich B, Voigt L, van Hooren B, Zanini M, Zinner C. ChatGPT Generated Training Plans for Runners are not Rated Optimal by Coaching Experts, but Increase in Quality with Additional Input Information. J Sports Sci Med. 2024;23:56-72. doi:10.52082/jssm.2024.56.

11. Feng H, Wang X. Comparative performance of four large language models in generating evidence-based exercise prescriptions using FITT-VP framework. Front. Physiol. 2026;17:1846567. doi:10.3389/fphys.2026.1846567.

12. Aydemir U. ChatGPT-Delivered Physical Activity Intervention for Children With Autism Spectrum Disorder: Pre-Post Feasibility Study. JMIR Hum Factors. 2025;12:e71119. doi:10.2196/71119.

13. Zhao T, Peng Y, Chen Z, Wang X. Physiological relevance and generation-level stability of artificial intelligence-generated race-day warm-up and cool-down plans for sprint swimming: an expert-rated comparison of four large language models. Front. Physiol. 2026;17:1923231. doi:10.3389/fphys.2026.1923231.

14. Philuek P, Kusump S, Sathianpoonsook T, Jansupom C, Sawanyawisuth P, Sawanyawisuth K, et al. The effects of chat GPT generated exercise program in healthy overweight young adults: A pilot study. J Hum Sport Exerc. 2025;20:169-179. doi:10.55860/1epqgp77.

15. Genç A, Aydin R, Canuzakov K, Abdurrahmanova D, Gürcan HH, Dere G, et al. Digital coaches: an alternative to expert coaches for men's fitness goals. Phys Act Rev. 2025;13(2):35-44. doi:10.16926/par.2025.13.18.

16. Shin D, Hsieh G, Kim YH. PlanFitting: Personalized Exercise Planning with Large Language Model-driven Conversational Agent. In: Proceedings of the 7th ACM Conference on Conversational User Interfaces (CUI 2025). 2025:1-19. doi:10.1145/3719160.3736607.

17. Schütze K, Shehatha R, Beer K, Needham M, Smith T, Bagg M, et al. Evaluating ChatGPT's advice and recommendations regarding exercise for people with inclusion body myositis. Neuromuscular Disorders. 2026;62:106418. doi:10.1016/j.nmd.2026.106418.

18. Bezruk V, Ivanov D, Ivanchuk M, Shkrobanets I, Makarova O, Rynzhuk L, et al. Impact of Query Language on the Structure and Guideline Alignment of AI-Generated Rehabilitation Programs in Chronic Kidney Disease. J Clin Med. 2026;15(11):4218. doi:10.3390/jcm15114218.

19. Sterne JAC, Savović J, Page MJ, et al. RoB 2: a revised tool for assessing risk of bias in randomised trials. BMJ. 2019;366:l4898. doi:10.1136/bmj.l4898.

20. Risk of Bias Tools. ROBINS-I Version 2. Updated November 20, 2025. https://www.riskofbias.info/welcome/robins-i-v2.

21. JBI. Critical appraisal tools. https://jbi.global/critical-appraisal-tools.

22. Wang M, Chen L, Yin M, Zhang B, et al. WMRE2030: integrating wearable devices, multi-omics, and artificial intelligence–driven real-time feedback into a daily-scale closed-loop framework for a new era of precision exercise. Front Physiol. 2026;17:1883295. doi:10.3389/fphys.2026.1883295.

23. Lee K. Cross-model consistency of AI-generated exercise prescriptions: A repeated generation study across three large language models. International Journal of Medical Informatics. 2026; article 106594. doi:10.1016/j.ijmedinf.2026.106594.

附录：35 项纳入研究报告清单（待按目标期刊格式统一）

W01. Dergaa I; Ben Saad H; El Omri A; Glenn J; Clark C; Washif J; et al. (2024). Using artificial intelligence for exercise prescription in personalised health promotion: A critical evaluation of OpenAI's GPT-4 model. DOI: 10.5114/biolsport.2024.133661.

W02. Havers T; Jelonnek C; Masur L; Isenmann E; Sperlich B; Geisler S; et al. (2025). A professional assessment of training plans for muscle hypertrophy and maximal strength developed by generative artificial intelligence. DOI: 10.5114/biolsport.2026.152350.

W03. He Z; Wang J; Zhang B; Li Y. (2026). Knowledge-grounded large language model for personalized sports training plan generation. DOI: 10.1038/s41598-026-37075-z.

W04. Washif J; Pagaduan J; James C; Dergaa I; Beaven C. (2024). Artificial intelligence in sport: Exploring the potential of using ChatGPT in resistance training prescription. DOI: 10.5114/biolsport.2024.132987.

W05. Havers T; Masur L; Isenmann E; Geisler S; Zinner C; Sperlich B; et al. (2025). Reproducibility and quality of hypertrophy-related training plans generated by GPT-4 and Google Gemini as evaluated by coaching experts. DOI: 10.5114/biolsport.2025.145911.

W06. Düking P; Sperlich B; Voigt L; Hooren BV; Zanini M; Zinner C. (2024). ChatGPT Generated Training Plans for Runners are not Rated Optimal by Coaching Experts, but Increase in Quality with Additional Input Information. DOI: 10.52082/jssm.2024.56.

W07. Feng H; Wang X. (2026). Comparative performance of four large language models in generating evidence-based exercise prescriptions using FITT-VP framework. DOI: 10.3389/fphys.2026.1846567.

W08. Perrero L; Gardalini M; Bolgeo T; Valorio P; Malfitano C; De Michelis V. (2026). Evaluation of AI-generated exercise prescriptions for diverse cardiac conditions in rehabilitation: a simulation study using the DeepSeek model. DOI: 10.3389/fresc.2026.1844420.

W09. Genç A; Aydın GR; Kasap M; Özkan A; Rakhymzhanov A; Gürcan HH; et al. (2026). Comparative evaluation of ChatGPT versions in training program design: scientific approach, accuracy, and practical applicability. DOI: 10.1186/s13102-025-01409-7.

W10. Akrimi S; Schwensfeier L; Düking P; Kreutz T; Brinkmann C. (2025). ChatGPT-4o-Generated Exercise Plans for Patients with Type 2 Diabetes Mellitus—Assessment of Their Safety and Other Quality Criteria by Coaching Experts. DOI: 10.3390/sports13040092.

W11. Xu Y; Liu Q; Pang J; Zeng C; Ma X; Li P; et al. (2024). Assessment of Personalized Exercise Prescriptions Issued by ChatGPT 4.0 and Intelligent Health Promotion Systems for Patients with Hypertension Comorbidities Based on the Transtheoretical Model: A Comparative Analysis. DOI: 10.2147/JMDH.S477452.

W12. Wachholz F; Manno S; Schlachter D; Gamper N; Schnitzer M. (2025). Acceptance and trust in AI-generated exercise plans among recreational athletes and quality evaluation by experienced coaches: a pilot study. DOI: 10.1186/s13104-025-07172-9.

W13. Lee K. (2026). Cross-model consistency of AI-generated exercise prescriptions: A repeated generation study across three large language models. DOI: 10.1016/j.ijmedinf.2026.106594.

W14. Sortino M; Trovato B; Chiaramonte R; Carrera A; Sapienza M; Roggio F; et al. (2026). The Role of Artificial Intelligence and Professional Expertise in Adapted Physical Activity Prescription for Orthopedic Rehabilitation. DOI: 10.3390/jfmk11010113.

W15. Choi M; Park J; Lee M; Beom J; Jung SY; Lee K. (2026). AI-Generated Exercise Prescriptions for At-Risk Populations: Safety and Feasibility of a Large Language Model Assessed by Expert Evaluation. DOI: 10.3390/jcm15062457.

W16. Cheng Q; Lou W; Mou G; Liu Y. (2026). Evaluating AI in postoperative rehabilitation of axillary web syndrome after breast cancer surgery: ChatGPT vs DeepSeek. DOI: 10.1080/01443615.2026.2695784.

W17. Aydemir U. (2025). ChatGPT-Delivered Physical Activity Intervention for Children With Autism Spectrum Disorder: Pre-Post Feasibility Study. DOI: 10.2196/71119.

W18. Yang Z; Zhang X; Li H; Ye J. (2026). More details, less variability? A crossover design study on the impact of information granularity on ChatGPT’s training program stability. DOI: 10.5114/biolsport.2026.154148.

W20. Cali A; Yorukoglu ME; Acar G; Safran E. (2026). ChatGPT-generated rehabilitation programs in sports physiotherapy: an expert evaluation and a mixed-methods study of clinical applicability. DOI: 10.3389/fmed.2026.1935702.

W21. Zhao T; Peng Y; Chen Z; Wang X. (2026). Physiological relevance and generation-level stability of artificial intelligence-generated race-day warm-up and cool-down plans for sprint swimming: an expert-rated comparison of four large language models. DOI: 10.3389/fphys.2026.1923231.

W22. Zaleski AL; Berkowsky R; Craig KJT; Pescatello LS. (2024). Comprehensiveness, Accuracy, and Readability of Exercise Recommendations Provided by an AI-Based Chatbot: Mixed Methods Study. DOI: 10.2196/51308.

W23. Li G; Li H; Su Y; Li Y; Jiang S; Zhang G. (2025). GPT-4 as a virtual fitness coach: a case study assessing its effectiveness in providing weight loss and fitness guidance. DOI: 10.1186/s12889-025-22739-8.

W24. Gürses ÖA; Özüdoğru A; Tuncay F; Karartı C. (2025). Artificial intelligence exercise recommendations in knee osteoarthritis rehabilitation: ChatGPT-4o and Gemini Advanced example. DOI: 10.54005/geneltip.1634118.

W25. Onan D; Arıkan H; Can İ; Güven Ş; Işıkay L; Ozge A. (2025). Examining the ability of artificial intelligence with ChatGPT-4.0 to create an exercise program: Case scenario examples “lumbar disc herniation, chronic migraine, and urge urinary incontinence”. DOI: 10.31459/turkjkin.1617953.

W26. Philuek P; Kusump S; Sathianpoonsook T; Jansupom C; Sawanyawisuth P; Sawanyawisuth K; et al. (2025). The effects of chat GPT generated exercise program in healthy overweight young adults: A pilot study. DOI: 10.55860/1epqgp77.

W27. Genç A; Aydin R; Canuzakov K; Abdurrahmanova D; Gürcan HH; Dere G; et al. (2025). Digital coaches: an alternative to expert coaches for men’s fitness goals. DOI: 10.16926/par.2025.13.18.

W28. Enichen EJ; Young CC; Frates EP. (2025). The Potential of AI to Create Personalized Exercise Plans. DOI: 10.1177/15248399251394695.

W29. Shin D; Hsieh G; Kim YH. (2025). PlanFitting: Personalized Exercise Planning with Large Language Model-driven Conversational Agent. DOI: 10.1145/3719160.3736607.

W30. Yang J; Qin S; Ren D. (2026). Artificial intelligence coaches on the sidelines: Evaluating readability and quality of soccer training plans from six generative models. DOI: 10.1177/17479541251369593.

W31. Schütze K; Shehatha R; Beer K; Needham M; Smith T; Bagg M; et al. (2026). Evaluating ChatGPT’s advice and recommendations regarding exercise for people with inclusion body myositis. DOI: 10.1016/j.nmd.2026.106418.

W32. Fu Y; Li H; You M; Wang L; Liu W; Zhou K; et al. (2026). Evaluation of Large Language Models in Generating Physical Exercise Rehabilitation Programs for Musculoskeletal Disorders Across Multiple Clinical Scenarios. DOI: 10.3390/healthcare14152389.

W33. Hüzmeli İ; Akkuş O. (2026). Usability of Large Language Models for Developing Exercise-Based Rehabilitation Programs in Patients With Stable Angina. DOI: 10.1155/ijcp/1434301.

W34. Montaruli G; Nikolaidis PT; Racil G; Maffulli N; Migliaccio GM; Padulo J. (2026). Artificial intelligence –generated marathon training programs: reliable tools in exercise prescription for athletic performance?. DOI: 10.1093/bmb/ldag010.

W35. Bezruk V; Ivanov D; Ivanchuk M; Shkrobanets I; Makarova O; Rynzhuk L; et al. (2026). Impact of Query Language on the Structure and Guideline Alignment of AI-Generated Rehabilitation Programs in Chronic Kidney Disease. DOI: 10.3390/jcm15114218.

W36. Rezaei H; Rabhi F; Beheshti A; Behnia A. (2026). PhysioAgent: A Multi-Agent AI Framework for Personalised Exercise Prescription and Longitudinal Adherence Monitoring in Physiotherapy. DOI: 10.1109/ICDH72779.2026.00045.